# Multitasking

Alexander Evgin

10 апреля 2020 г.

#### Outline

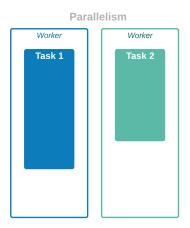
- 1 Parallelism vs concurrency
- 2 Processes and threads Threads synchronization Processes synchronization GIL

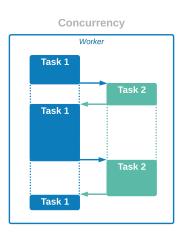
3 Asynchronous functions

Task execution

## Parallelism vs Concurrency

## Parallelism vs Concurrency





#### **Process**

- *Процесс* запущенная программа.
- Окружение процесса:
  - виртуальное адресное пространство
  - указатель на исполняемую инструкцию
  - стек вызовов
  - таблица дескрипторов
- У каждого процесса своё изолированное окружение.
- Процессы удобны для одновременного выполнения нескольких задач.
- Процессы могут создавать другие (дочерние) процессы.
- Альтернативный способ: делегировать каждую задачу на выполнение потоку.

#### **Process**

#### Linux:

- Создание процесса: системный вызов fork
- Дочерние процессы наследуют окружение от родительских
- Иерархия процессов

#### Windows NT:

- Создание процесса: системный вызов NtCreatProcess
- Дочерние процессы имеют произволное требуемое окружение

# Thread (поток, тред, "нить")

- Поток единица выполнения задачи. Чаще всего поток находится "внутри" процесса. Его исполнение происходит независимо от других потоков и процессов.
- Поток разделяет все ресурсы процесса. У нескольких поток одного процесса общие данные и системные ресурсы.
- Потоки удобны для одновременного выполнения нескольких задач, которым требуется доступ к разделяемому состоянию (общей памяти).

#### Processes and threads

- Потоки и процессы единицы объекты операционной системы. Операционная система управляет их выполнением (Process Scheduling).
- Реализация зависит от операционной системы.
- Эффективность зависит от ресурсов системы. Единица выполнения — ядро процессора.

### Модуль subprocess

Позволяет создавать подпроцессы (дочерние процессы). Каждый из них — самостоятельная программа со своим окружением.

```
main.py

import subprocess as sp

proc = sp.run(['py', 'child.py'])

child.py
print('Hello, world!')
```

## Модуль multiprocessing

Интерфейс позволяет запускать функции как подпроцессы.

```
import multiprocessing as mp

def greeting(name: str):
    print(f'Hello, {name}')

if __name__ == "__main__":
    child = mp.Process(target=greeting, args=('User',))
    child.start()
```

- subprocess удобнее вызывать сторонние (не python) приложения
- multiprocessing удобнее производить параллельные вычисления в одной программе

## Модуль threading

Позволяет создавать новые потоки. Поток в Python — это системный поток, его выполнением управляет не интерпретатор, а операционная система.

```
from threading import Thread

def greeting(name: str):
    print(f'Hello, {name}')

t = Thread(target=greeting, args=('User',))
t.start()
```

### Имя и идентификатор потока

```
При создании потоку можно указать имя. По умолчанию оно "Thread-N":

>>> Thread().name
'Thread-1'
>>> Thread(name="NumberCruncher").name
'NumberCruncher'
```

У каждого активного потока есть идентификатор — неотрицательное число, уникальное для всех активных потоков.

```
>>> t = Thread()
>>> t.start()
>>> t.ident
4350545920
```

#### Присоединение потоков

Один поток может дождаться исполнения другого. Выполнение потока приостановится, пока не завершится поток t.

```
Meтoд join():

>>> t = Thread(target=time.sleep, args=(5, ))

>>> t.start()

>>> t.join() # блокируется на 5 секунд

>>> t.join() # выполняется моментально
```

Норма: корневой поток дожидается всех остальных. В таких случаях происходит корректное завершение всех потоков (закрытие файлов, освобождение семафоров). Python *не имеет* встроенного корректного завершения потоков.

#### Присоединение потоков

Проверить, выполняется ли поток, можно с помощью метода is\_alive():

```
>>> t = Thread(target=time.sleep, args=(5, ))
>>> t.start()
>>> t.is_alive()
True
>>> t.is_alive() # через 5 секунд
False
```

## Синхронизация потоков

У потоков в одном процесса общая память. Следовательно, несколько потоков могут менять одно и тоже значение. Это может привести к непредсказуемому поведению (undefined behavior).

#### Примитивы синхронизации:

- Мьютекс выставляемый флаг (0 или 1). Используется для обеспечения эксклюзивного доступа к разделяемому состоянию.
- Семафор численный счетчик. Позволяет захватывать и освобождать себя нескольким потокам сразу (увеличивать и уменьшать свое значение на 1).
- ...

### Синхронизация потоков: мьютекс

Мьютекс threading.Lock:

```
class SharedCounter:
def __init__(self, value):
    self.value = value
    self._lock = Lock()

def increment(self, delta=1):
    self._lock.acquire()
    self.value += delta
    self._lock.release()
```

acquire() блокируется до тех пор, пока счетчик не станет свободным (другой поток не вызовет release()).

## Синхронизация потоков: событие

С помощью threading. Event можно организовать ожидание некоторого "события" одним или более потоками:

```
io_ready = Event()

def initialize_logging():
    io_ready.wait()

# ...

def initialize_disk_io():
    # ...

io_ready.set()
```

Bce задачи c initialize\_logging будут ждать, пока не выполнится initialize\_disk\_io.

### Синхронизация потоков: условные переменные

threading.Condition используется для отправки сигналов между потоками. Метод wait() блокирует вызывающий поток, пока какой-то другой поток не вызовет метод notify() или  $notify_all()$ .

```
q = deque()
    is_empty = Condition()
3
    def producer():
4
        while True:
5
             is_empty.acquire()
6
             q.append(...)
7
             is_empty.notify()
8
             is_empty.release()
9
10
    def consumer():
11
        while True:
12
             is_empty.acquire()
13
             while not q:
14
                 is_empty.wait()
15
             ... = q.popleft()
16
             is_empty.release()
17
```

### Синхронизация потоков: пример

Функция follow читает сообщения из переданного ей соединения и кладёт их в очередь на обработку.

```
def follow(connection, connection_lock, q):
       try:
2
            while True:
3
                connection_lock.acquire()
4
                message = connection.read_message()
5
                connection_lock.release()
6
                q.put(message)
       except InvalidMessage:
            follow(connection, connection_lock, q)
9
10
   follower = Thread(target=follow, args=...)
11
   follower.start()
12
```

## Синхронизация потоков: пример

Функция follow читает сообщения из переданного ей соединения и кладёт их в очередь на обработку.

```
def follow(connection, connection_lock, q):
       try:
2
            while True:
3
                connection_lock.acquire()
4
                message = connection.read_message()
5
                connection_lock.release()
                q.put(message)
       except InvalidMessage:
            follow(connection, connection_lock, q)
9
10
   follower = Thread(target=follow, args=...)
11
   follower.start()
12
```

Вопрос: что может пойти не так?

### Синхронизация потоков

Чтобы методы acquire() и release() не засоряли код и не порождали ошибки, все примитивы синхронизации поддерживают протокол контекстного менеджера:

```
def follow(connection, connection_lock, q):
    try:
    while True:
    with connection_lock:
        message = connection.read_message()
        q.put(message)
    except IOError:
    follow(connection, connection_lock, q)
```

### Модуль queue: safe-thread

Модуль queue реализует несколько потокобезопасных очередей:

- Queue FIFO очередь,
- LifoQueue LIFO очередь aka стек,
- PriorityQueue очередь, элементы которой пары вида (priority, item).
- Никаких особых изысков в реализации очередей нет: все методы, изменяющие состояние, работают "внутри" мьютекса.
- Класс Queue использует в качестве контейнера deque, а классы LifoQueue и PriorityQueue — список.

### Модуль queue: пример

```
def worker(q):
    while True:
        item = q.get() # блокирующе ожидает следующий
        do_something(item)
        q.task_done() # уведомляет очередь о выполнении
                      # задания
def master(q):
    for item in source():
        q.put(item)
    q.join() # блокирующе ожидает, пока все элементы
             # очереди не будут обработаны
```

### Синхронизация процессов

- Разные окружения, нет общей памяти.
- Операционная система предоставляет механизм взаимодействия: Inter-process communication (IPC):
  - Signal
  - Named pipe / Anonymous pipe
  - Shared memory
  - Socket / Unix domain socket
  - Message queue (probably the best)
  - ..

### Синхронизация процессов

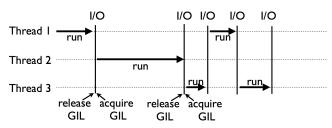
```
proc = subprocess.run(['py', 'child.py'],
                          capture_output=True)
2
  print(proc.stdout) # b'Hello, world!'
  from multiprocessing import Process, Value
2
  def func(val):
      val.value += 1
4
5
_{6} v = Value('i', 0)
  Process(target=func, args=(v,)).start()
```

## GIL

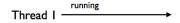
# Global Interpreter Lock (GIL)

GIL — глобальный мьютекс интерпретатора, который гарантирует, что в каждый момент времени только один поток имеет доступ к внутреннему состоянию интерпретатора.

- GIL это фича интерпретатора CPython.
- *Идея:* В CPython всегда исполняется только один поток (на самом деле нет).
- **Ho:** GIL может быть освобожден (released) с помощью Python C API: например, все операции ввода/вывода в CPython отпускают GIL.



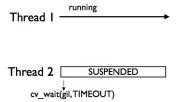
 Предположим, что программа использует только один поток. GIL принадлежит потоку. Ничего интересного не происходит.



 Что произойдёт при появлении второго потока? Ничего: GIL всё ещё принадлежит первому потоку. Второй поток должен каким-то образом его получить.

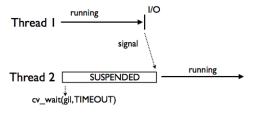


 Второй поток ожидает GIL в течении промежутка времени TIMEOUT в надежде, что первый поток сам освободит GIL, например, в результате операции ввода/вывода.

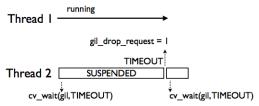


 Далее возможны два случая в зависимости от того, отпустил первый поток GIL или нет.

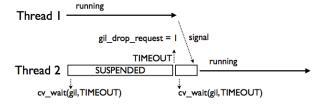
- Простой случай: первый поток отпускает GIL и сигнализирует об этом второму потоку.
- Второй поток захватывает GIL и начинает исполнение.



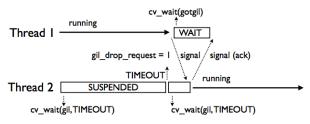
 Сложный случай: второй поток сигнализирует первому потоку о своём желании захватить GIL, устанавливает глобальный флаг gil\_drop\_request и повторяет ожидание.



• Первый поток завершает выполнение текущей инструкции, отпускает GIL и сигнализирует об этом второму потоку.



- Первый поток ожидает уведомление об успешном захвате GIL первым потоком. Это сделано для того, чтобы предыдущий владелец GIL не мог захватить его повторно ("GIL Battle").
- Второй поток захватывает GIL, отправляет первому потоку уведомление и начинает исполнение.



## Global Interpreter Lock (GIL)

Ещё раз: GIL запрещает *физическую параллельность* потоков. Это защищает от неправильной работы интерпретатора, но не защищает от вашего собственного кода:

```
counter += 1 (read counter \rightarrow calculate counter + 1 \rightarrow write self.counter)
```

Плохой сценарий (в котором в каждый момент выполняется один поток):

- thread1 reads counter (0)
- thread2 reads counter (0)
- thread1 calculates number + 1 (1)
- thread2 calculates number + 1 (1)
- thread1 writes 1 to number
- thread2 writes 1 to number

Pезультат: counter = 1

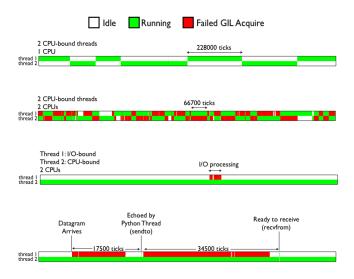
## GIL — good or bad?

Ответ зависит от вашей задачи.

- + Однопоточный код выполняется быстрее (один Lock, JIT)
- + Решает проблему счетчика ссылок (reference counter)
- + GIL не мешает использовать потоки для конкурентности при работе с вводом/выводом
- + Упрощение интеграции с C, который не thread-safe

- Невозможность использовать потоки в Python для параллелизма: несколько потоков не ускоряют, а иногда даже замедляют работу программы
- "GIL Battle" несколько потоков бьются за владение GIL

#### GIL Battle



David Beazley

Why hasn't the GIL been removed yet?

I'd welcome a set of patches into Py3k only if the performance for a single-threaded program (and for a multi-threaded but I/O-bound program) does not decrease.

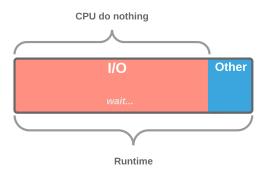
Guido van Rossum

Asynchrony

### Asynchrony

Практически все программы тратят большую часть времени своей работы на I/O операции.

(Ядро Linux: I/O - ≈ 86% CPU time, но это не точно)



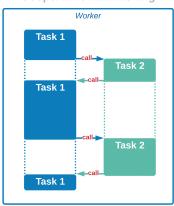
### Asynchrony

Асинхронное выполнение в Python — это кооперативная многозадачность.

Preemptive multitasking

Scheduler Task 1 Task 2 Task 1 Task 1

Cooperative multitasking



### Асинхронные паттерны

У исполняемой задачи может быть два состояния: вычисление и ожидание. Ожидание — самое время, чтобы передать выполнение другой задаче.

- Корневая задача цикл исполнения
- Отслеживание "готовности к выполнению" в задаче (ready to read/write, системный вызов)
- Переключение контекста выполнения между задачами (selector-ы / генераторы)

## Асинхронность в Python

- Асинхронность на системный вызовах готовности (select, event loop)
- Асинхронность на генераторах и сопрограммах (coroutine, yield from)
- Модуль asyncio, синтаксис async/await

## Интерфейс asyncio

```
import asyncio
1
2
3
    async def foo():
        print('foo...1')
4
        await asyncio.sleep(0.1)
5
        print('foo...2')
6
        await asyncio.sleep(0.3)
7
        print('foo...3')
8
9
    async def bar():
10
        print(' bar...1')
11
        await asyncio.sleep(0.2)
12
        print(' bar...2')
13
        await asyncio.sleep(0.1)
14
        print(' bar...3')
15
16
17
    ioloop = asyncio.get_event_loop()
    ioloop.run_until_complete(asyncio.wait([foo(), bar()]))
18
```